UNIVERSIDADE FEDERAL DE VIÇOSA
Departamento de Informática — Programa de Pós-Graduação em Ciência da Computação
INF 791 — Tópicos Especiais II: Processamento de Linguagem Natural

Projeto Final
Etapa 1 — Definição de Tema

Ana Clara Guerra - 108205

Tema: Impacto do pré-processamento linguístico na recuperação semântica de documentos científicos.

1. Tema e motivação

Este trabalho será desenvolvido como uma extensão complementar do meu projeto de mestrado, explorando uma questão específica que surgiu a partir do desenvolvimento do *AmazoniaExpert.AI* e do benchmark SPAmazon-QA.

O foco será investigar como diferentes estratégias de pré-processamento linguístico podem afetar a recuperação semântica em um sistema RAG. Técnicas como *lowercase*, remoção de *stopwords*, lematização e *stemming* são muito comuns em Processamento de Linguagem Natural (PLN), mas seu efeito em modelos modernos de *embeddings* contextuais nem sempre é evidente.

Portanto, a proposta é avaliar de forma controlada como essas transformações impactam a recuperação dos documentos científicos associados às perguntas do *SPAmazon-QA* e, de forma complementar, observar se mudanças no contexto recuperado também podem se refletir na qualidade das respostas geradas pelo *AmazoniaExpert.IA*.

2. Questões de pesquisa

A questão principal que orientará o trabalho é:

RQ1: Como diferentes estratégias de pré-processamento linguístico afetam a recuperação semântica de capítulos de origem de perguntas científicas sobre a Amazônia?

Serão comparadas cinco condições: texto original sem novo pré-processamento (P0), *lowercase* (P1), *lowercase* com remoção controlada de *stopwords* (P2), *lowercase* com lematização (P3) e *lowercase* com *Porter stemming* (P4).

Além da comparação de desempenho, o trabalho também investigará duas questões complementares:

RQ2: Alterações provocadas pelo pré-processamento na recuperação semântica se propagam para a qualidade das respostas geradas por um sistema RAG em casos críticos?

RQ3: Em que medida as estratégias de pré-processamento alteram a tokenização e a representação vetorial produzida pelo `all-mpnet-base-v2`, e essas alterações estão associadas à estabilidade do ranking e ao desempenho de recuperação?

A hipótese central é que técnicas tradicionais de pré-processamento não necessariamente melhoram sistemas de recuperação baseados em *embeddings* contextuais. Transformações mais agressivas podem modificar a tokenização e a representação vetorial dos textos, afetando o ranking dos documentos recuperados e, em alguns casos, também o contexto fornecido ao sistema RAG.

3. Base de dados

Serão utilizados o corpus científico do Science Panel for the Amazon (SPA) e o benchmark SPAmazon-QA, previamente estruturados no contexto do *AmazoniaExpert.AI*. O corpus contém 38 documentos científicos, correspondentes a 1.337 páginas, segmentados em aproximadamente 6.900 chunks textuais. O *SPAmazon-QA* contém 130 pares de perguntas e respostas científicas, associados aos capítulos de origem utilizados como referência na avaliação.

A base é adequada ao problema porque combina textos científicos extensos, especializados e semanticamente próximos entre si com perguntas de diferentes níveis de dificuldade. Isso permite avaliar de forma controlada se modificações linguísticas realizadas antes da geração dos *embeddings* alteram a capacidade do sistema de relocalizar o documento de origem da informação. A recuperação será realizada com o encoder `sentence-transformers/all-mpnet-base-v2` e os resultados serão avaliados por métricas como Hit@k e MRR.