

Impacto do pré-processamento linguístico na recuperação semântica de documentos científicos

Planejamento técnico e experimental - 30 dias - Versão 3: preservação semântica e Caso 11

Decisão principal: usar somente recuperação semântica com embeddings e ChromaDB. Sem BM25, sem geração de respostas por LLM e sem alterar o corpus ou seus chunks. A nova versão acrescenta uma análise explícita de preservação semântica de restrições temporais, negações, quantidades e comparações.

Base de referência	Escopo	Dados de avaliação
AmazoniaExpert.IA (TCC)	5 variantes P0-P4 de pré-processamento	130 perguntas do SPAmazon-QA
all-mpnet-base-v2 + ChromaDB	Uma variável experimental por vez	Capítulo de origem + análise de restrições semânticas
Caso sentinela	ID 11 - restrição temporal "since the 1970s"	Análise obrigatória em P0-P4

Autoria: Ana Clara Guerra Torres | Disciplina de Processamento de Linguagem Natural | Outubro de 2026

TRABALHO FINAL DE PROCESSAMENTO DE LINGUAGEM NATURAL

1. Visão geral, perguntas de pesquisa e limites

O trabalho investiga se operações clássicas de PLN alteram a posição e a adequação semântica dos fragmentos recuperados pelo mecanismo denso já utilizado no AmazoniaExpert.IA. O corpus do TCC e o SPAmazon-QA são reutilizados; o foco permanece na etapa de recuperação, não na geração final por LLM.

Pergunta principal: Como diferentes estratégias de pré-processamento linguístico afetam a recuperação semântica de capítulos de origem de perguntas científicas sobre a Amazônia?

Pergunta secundária: Como essas estratégias se comportam quando a consulta contém restrições linguísticas críticas - especialmente temporalidade, negação, quantidade e comparação?

Objetivo geral

Avaliar, de forma controlada e reprodutível, o efeito do pré-processamento textual sobre a recuperação densa do corpus científico amazonico, mantendo constantes documentos, chunks, metadados, modelo de embeddings, parâmetros de busca e conjunto de consultas.

Objetivos específicos

- Reproduzir P0 como linha de base do AmazoniaExpert.IA.
- Implementar P1-P4 e testar seus efeitos sobre corpus e consultas em inglês.
- Comparar a posição do capítulo-alvo nas 130 consultas.
- Investigar se transformações removem ou distorcem marcadores linguísticos decisivos.
- Analisar obrigatoriamente o Caso 11 e outros casos críticos representativos.
- Documentar uma política de pré-processamento reutilizável no mestrado.

Dentro x fora do escopo

Inclui	Não inclui
Lowercase, stopwords, lematização, stemming	BM25, recuperação híbrida, reranking, GraphRAG
Embeddings + ChromaDB	Novo chunking, expansão do corpus, nova extração de PDFs
Hit@k, MRR e análise linguística de casos	Geração por LLM, Juiz LLM, fine-tuning

MOTIVAÇÃO

2. O Caso 11 como evidência do problema de recuperação

O TCC já registrou um caso concreto em que a recuperação semântica falhou por não respeitar uma restrição temporal da pergunta. Esse episódio passa a ser um dos principais motivadores do trabalho de PLN.

Caso 11: a pergunta solicitava tres atividades extrativistas ou commodities que se expandiram na Amazônia a partir da década de 1970. O sistema recuperou um fragmento com escopo histórico anterior a esse período, levando o AmazoniaExpert.IA a omitir elementos contemporâneos esperados.

Por que esse caso e importante para PLN?

- **Restrição temporal:** "since the 1970s" não e um detalhe superficial; define o intervalo histórico valido.
- **Similaridade lexical insuficiente:** chunks sobre atividades economicas antes e depois de 1970 podem compartilhar quase o mesmo vocabulário.
- **Risco do pré-processamento:** remover palavras funcionais ou reduzir formas morfológicas pode preservar o tema geral, mas enfraquecer a relação temporal.
- **Diagnóstico além do capítulo:** mesmo quando o capítulo correto aparece, o chunk pode satisfazer ou violar uma restrição específica da pergunta.

Exemplo conceitual

Consulta / chunk	Conteúdo	Interpretação
Pergunta	activities expanded in the Amazon since the 1970s	Exige período posterior/iniciado nos anos 1970
Chunk A	extractive activities before the 1970s	Tema semelhante, relação temporal incompatível
Chunk B	cattle, soy and mining expanded since the 1970s	Tema e relação temporal compatíveis
Hipótese pratica: uma política de pré-processamento deve preservar não apenas palavras temáticas, mas tambem os operadores linguísticas que determinam o sentido da consulta.		

DADOS

3. SPAmazon-QA: estrutura real e uso no experimento

O SPAmazon-QA contém 130 questões. O trabalho não reescrevera o benchmark: ele sera usado em modo somente leitura, e os novos rankings e métricas serao gravados em arquivos separados.

Campo	Papel no projeto
id_questão	Chave estavel para unir rankings, métricas e análises.
conjunto_curado.pergunta	Texto da consulta; recebe a mesma variante P0-P4 aplicada ao corpus.
metadados_pergunta.capitulo_alvo	Rótulo operacional de origem; nunca entra na busca.
metadados_pergunta.tipo	Análise Direct x Indirect.
metadados_pergunta.dificuldade	Análise Easy / Medium-Low / Medium-High / Hard.
indice_subjetividade	Análise exploratoria complementar.
resposta_esperada	Apoio qualitativo para interpretar ganhos/perdas e casos sentinela.

Resultados históricos que permanecem fora da nova recuperação

- avaliacoes_modelos, respostas antigas e notas do Juiz LLM;
- similaridade_faiss_percentual e booleano capitulo_recuperado do TCC;
- modelo_gerador_qa como entrada da busca.

Regra: o SPAmazon-QA original nunca sera sobrescrito. O benchmark fornece consultas, metadados e referência de origem; o experimento novo produz arquivos derivados.

NORMALIZAÇÃO

4. Regra de equivalência dos capítulos

O protocolo trabalha com identificadores canônicos de origem para evitar que grafias diferentes do mesmo documento sejam tratadas como capítulos distintos.

Equivalência confirmada: cross_chapter_2 = cc2 = CC2 = Capítulo CC2 = Capítulo Cross Chapter 2	
Valor recebido	Identificador canônico
Capítulo CC2 / CC2 / cc2	cross_chapter_2
Capítulo Cross Chapter 2 / cross_chapter_2	cross_chapter_2
Capítulo Cross Chapter 1 / cross_chapter_1	cross_chapter_1
Capítulo 1 ... Capítulo 34	chapter_01 ... chapter_34
Capítulo Annex 1 / Annex 2	annex_01 / annex_02

Regras obrigatórias

- Aplicar a mesma função de canonicalização ao capítulo-alvo do QA e ao chapter_number dos chunks.
- Preservar a grafia original em campo separado para auditoria.
- Não criar novo capítulo para CC2 e não usar cross_chapter_0.
- Valor desconhecido deve gerar erro explícito, nunca mapeamento silencioso.
- Criar testes positivos e negativos para cross_chapter_1 e cross_chapter_2.

Contrato de teste

```
assert canonicalize("Capítulo CC2") == "cross_chapter_2"
assert canonicalize("cc2") == "cross_chapter_2"
assert canonicalize("Capítulo Cross Chapter 2") == "cross_chapter_2"
assert canonicalize("Capítulo Cross Chapter 1") == "cross_chapter_1"
```

VARIANTES

5. P0-P4: somente a preparação linguística muda

Todas as condicoes partem do mesmo texto enriquecido usado no TCC - incluindo a in-text metadata injection de capítulo e seção. A única variável experimental e a transformacao textual aplicada antes do encoder.

Var.	Operacao controlada	Pergunta interpretativa
P0	Texto original da recuperação do TCC	Qual e o desempenho da baseline?
P1	Lowercase somente	A caixa de letras altera os rankings?
P2	P1 + remocao controlada de stopwords	Remover palavras funcionais ajuda ou elimina relações importantes?
P3	P1 + lematização em inglês	A redução a formas canônicas melhora a recuperação?
P4	P1 + stemming em inglês	Uma redução morfológica mais agressiva ajuda ou degrada?

Tratamento simétrico

- Para cada Pk, processar chunks e perguntas com exatamente a mesma variante.
- Não pre-processar capítulo-alvo ou metadados usados apenas para avaliação.
- Guardar texto_original e texto_processado.
- Nenhuma regra pode ser ajustada depois de observar os resultados.
- Cada variante deve gerar texto não vazio e passar por amostragem manual.

Ponto novo da versão 3: P2 não usara uma stoplist de forma cega. A lista sera congelada antes do experimento e auditada para preservar marcadores linguísticas que carregam restrições semânticas.

PRESERVAÇÃO SEMÂNTICA

6. Marcadores linguísticas críticos: o que não pode desaparecer

O experimento passa a tratar explicitamente certos termos como potencialmente decisivos para o sentido científico da consulta. A lista abaixo é uma lista de auditoria, não uma regra automática definitiva; a stoplist final será documentada e congelada antes das execuções.

Categoria	Exemplos a auditar	Risco se removidos/distorcidos
Temporalidade	before, after, since, until, during, between, earlier, later, prior, following	Recuperar período histórico oposto ou inadequado.
Negação	not, no, nor, without	Inverter a polaridade da consulta.
Quantidade / limite	more, less, at least, at most, above, below, how much	Perder magnitude, limiar ou direção numérica.
Comparação	higher, lower, greater, smaller, than, versus	Misturar entidades ou relações comparativas.
Causalidade / condição	why, because, under, if, when	Trocar relação causal por simples associação.

Tokens técnicos a preservar

- Datas, décadas e intervalos temporais: 1970, 1970s, 2021, 1990-2000.
- Unidades e quantidades: Pg C, %, km2, Mg/ha, concentrações e limites.
- Siglas e símbolos: CO2, P, N, RIL, ZRC, nomes próprios técnicos.
- Sinais de comparação quando presentes no texto: >, <, +/-, ranges.

Caso 11 será o primeiro teste sentinela para verificar se "since the 1970s" continua orientando a recuperação para evidências temporalmente compatíveis.

DESENHO EXPERIMENTAL

7. Fluxo e integração dos componentes

O fluxo mantém o corpus, os chunks, o encoder e a base de consultas constantes. Como cada variante altera o texto enviado ao encoder, cada Pk precisa de uma coleção ChromaDB própria.

Etapa	Entrada	Saída
1. Congelar fontes	VECTOR_DB original + SPAmazon-QA	Hashes, versoes, inventario
2. Validar dados	Chunks + QA	IDs, aliases, campos obrigatórios
3. Reproduzir P0	Texto enriquecido original	Baseline auditada
4. Gerar P1-P4	Mesmos chunks / perguntas	Textos processados
5. Embeddings	all-mpnet-base-v2 fixo	Vetores por variante
6. Indexacao	Vetores + metadados	5 coleções ChromaDB
7. Recuperação	130 perguntas x 5 variantes	Top-10 por consulta
8. Avaliação	Rankings + alvo canônico	Hit@k, MRR, rank
9. Análise semântica	Casos críticos / sentinelas	Diagnóstico de restrições

Ordem: validação -> baseline -> variantes -> indexacao -> consulta -> métricas -> análise semântica -> discussão.

Regra de controle experimental

- Mesmo conjunto de documentos e chunks.
- Mesmo modelo de embeddings e configuração do encoder.
- Mesma métrica do ChromaDB e mesmo Top-10.
- Mesmas 130 perguntas.
- Somente o pré-processamento varia.

AVALIAÇÃO

8. Métricas quantitativas + análise linguística

O SPAmazon-QA identifica o capítulo de origem, não cada chunk relevante. Por isso, a avaliação quantitativa principal mede se o capítulo-alvo aparece no ranking. A análise de preservação semântica complementa essa medida nos casos críticos.

Métrica	Definicao	Papel
Chapter Hit@1/@3/@5/@10	1 se algum chunk do capítulo-alvo aparece no Top-k; 0 caso contrario.	Principal
MRR@10	1/r para a primeira posição r <= 10 do capítulo-alvo; 0 se ausente.	Principal
Rank do primeiro acerto	Posição do primeiro chunk do capítulo correto.	Diagnóstico
Delta versus P0	Diferenca pareada de Hit@k e MRR por questão.	Comparação

Análise de preservação semântica

- Selecionar casos com restrições temporais, negação, quantidade ou comparação.
- Para cada caso, comparar os Top-10 de P0-P4 e ler os trechos recuperados.
- Registrar se o primeiro contexto relevante respeita a restrição expressa na pergunta.
- Usar a resposta esperada apenas para entender o sentido requerido, não como entrada da recuperação.
- Tratar essa etapa como análise qualitativa/diagnostica, não como nova métrica automática sem anotação formal.

Importante: acerto de capítulo não garante acerto da evidência. O novo diagnóstico serve justamente para identificar casos em que o tema esta correto, mas a relação temporal, negativa, quantitativa ou comparativa esta errada.

CASOS SENTINELA

9. Protocolo de análise do Caso 11 e de outros casos críticos

O Caso 11 será analisado independentemente do desempenho agregado. Ele funciona como um caso sentinela porque o TCC já documentou a falha e sua causa interpretativa.

Campo a registrar	Exemplo / pergunta
id_questão	11
restrição	Temporal: "since the 1970s"
capítulo_alvo	Capítulo 17
P0-P4: primeiro chunk correto	Rank e capítulo
Compatibilidade temporal	O chunk fala de expansão a partir dos anos 1970?
Termos preservados	since / 1970s e outros marcadores
Diagnóstico	Melhora, empate, degradacao ou erro diferente

Modelo de leitura do ranking

1. Verificar se o capítulo-alvo aparece no Top-10.
2. Localizar o primeiro chunk potencialmente útil.
3. Checar se o recorte temporal/relacional é compatível com a pergunta.
4. Comparar o mesmo caso em P0, P1, P2, P3 e P4.
5. Explicar a mudança pelo texto efetivamente enviado ao encoder, sem atribuir causalidade além do observado.

Expansão da análise

- Selecionar ao menos 3-5 casos adicionais de temporalidade, se existirem no SPAmazon-QA.
- Selecionar exemplos de negação, quantidade e comparação quando houver ocorrências claras.
- Priorizar casos em que Pk altera fortemente o ranking ou transforma tokens críticos.

DADOS DERIVADOS

10. Arquivos de resultados e contratos de integração

Os resultados novos ficam totalmente separados do SPAmazon-QA original e do VECTOR_DB de referência.

Arquivo	Conteúdo
results/raw/rankings.csv	question_id, variant, rank, chunk_id, chapter_original, chapter_id, target_id, distance, hit
results/metrics/question_metrics.csv	Hit@1/3/5/10, primeira posição, RR por pergunta/variante
results/metrics/summary.csv	Resultados agregados P0-P4, total e estratos
results/semantic/case_analysis.csv	Casos sentinela: restrição, termos preservados, compatibilidade, diagnóstico
results/figures/	Graficos, tabelas de mudanca de ranking e casos críticos
results/runs/	Config, hashes, versoes e logs de cada execução

Contrato minimo de caso semântico

question_id,variant,constraint_type,constraint_text,first_target_rank,
constraint_preserved_in_query,context_compatible,notes

A coluna context_compatible sera usada apenas nos casos analisados manualmente. Não sera inferida automaticamente para todas as 130 perguntas sem uma anotação específica.

IMPLEMENTAÇÃO

11. Stack, repositório, configuração e comandos

Camada	Tecnologia	Responsabilidade
Linguagem	Python 3.11+	Pipeline e experimentos
PLN	re, spaCy en_core_web_sm, NLTK	Lowercase, stopwords, lemas, stems
Embeddings	sentence-transformers / all-mpnet-base-v2	Representacao fixa
Banco vetorial	ChromaDB	5 coleções e Top-10
Análise	pandas, numpy, scipy opcional	Métricas e comparações
Graficos	matplotlib	Figuras reproduzíveis
Config	PyYAML, pathlib, logging	Parâmetros e rastreabilidade
Testes	pytest	Aliases, pré-processamento e métricas

Estrutura sugerida

```
TRAB FINAL/  
  VECTOR_DB/          # referência original - somente leitura  
  SPAmazon-QA.json     # benchmark original - somente leitura  
  configs/experiment.yaml  
  src/{loaders,chapters,preprocess,index,retrieve,metrics,semantic}.py  
  scripts/{validate_data,inspect_chromadb,build_collections,run_retrieval,analyze_results}.py  
  tests/{test_chapters,test_preprocess,test_metrics,test_semantic_rules}.py  
  results/{raw,metrics,semantic,figures,runs}/
```

Comandos previstos

```
python scripts/validate_data.py --config configs/experiment.yaml  
pytest -q  
python scripts/build_collections.py --config configs/experiment.yaml  
python scripts/run_retrieval.py --config configs/experiment.yaml  
python scripts/analyze_results.py --config configs/experiment.yaml
```

CRONOGRAMA

12. Execução em 1 mes - versão atualizada

Semana	Dias	Execução	Checkpoint
1 - Preparação e baseline	1-7	Inventariar QA/VECTOR_DB, hashes, aliases, inspecionar ChromaDB, reproduzir P0 e localizar Caso 11.	Dados aprovados + P0 + Caso 11 reproduzido.
2 - PLN e indexacao	8-14	Implementar P1-P4; congelar stoplist; testar temporalidade/negação/unidades ; auditar amostras; criar índices.	5 coleções + regras semânticas testadas.
3 - Experimentos	15-21	130 x 5 consultas, Top-10, Hit@k, MRR, deltas; executar análise dos casos sentinela.	Rankings + métricas + fichas semânticas.
4 - Interpretação e entrega	22-30	Selecionar ganhos/perdas, discutir Caso 11, produzir figuras, escrever relatório e README.	Relatório + repositório reproduzível.

Portoes de qualidade

- G1: 130 questões validas, aliases corretos, VECTOR_DB auditado e P0 reproduzido.
- G2: P1-P4 deterministicas, nenhuma consulta/chunk vazio e marcadores críticos auditados.
- G3: 6.500 posições Top-10 registradas (130 x 5 x 10) ou excecoes documentadas.
- G4: Caso 11 e outros casos críticos discutidos com base nos rankings e textos processados.
- G5: Conclusoes limitadas a recuperação; sem prometer melhora na geração final sem testa-la.

Prioridade da Semana 1: antes de qualquer P1-P4, confirmar exatamente como P0 recupera o Caso 11 hoje. Esse resultado sera nossa referência para toda a análise temporal.

RISCOS E INTERPRETAÇÃO

13. Riscos, limites e ligação com o mestrado

Risco	Medida preventiva
Stopwords removem relações temporais/negações	Auditar e congelar lista protegida antes dos experimentos.
Stemming deforma termos técnicos	Inspecionar amostras, siglas, unidades e palavras-chave científicas.
Hit de capítulo mascara chunk inadequado	Complementar com análise de preservação semântica nos casos críticos.
Ajuste pos-hoc da stoplist	Proibir mudancas apos observar desempenho.
Scores entre coleções interpretados como equivalentes absolutos	Comparar rankings e métricas, não apenas distancias brutas.
Generalizacao excessiva	Relatar que o estudo usa um corpus, um encoder e um benchmark específicos.

O que sera aproveitado no mestrado

- Política de pré-processamento validada para recuperação densa em corpus científico.
- Lista documentada de marcadores que devem ser preservados em consultas técnicas.
- Protocolo de diagnóstico de erros de recuperação além do simples acerto de capítulo.
- Casos sentinela reutilizáveis em futuros testes de recuperação híbrida, reranking, hierárquica e GraphRAG.

Contribuição esperada: demonstrar quando o pré-processamento ajuda, quando e neutro e quando pode destruir informacao relacional essencial para a recuperação científica.

ENTREGA

14. Estrutura do relatório final e decisões consolidadas

Parte	Conteúdo
1. Introdução	Problema, AmazoniaExpert.IA, Caso 11 e relação com o mestrado.
2. Perguntas e hipóteses	Pergunta principal + secundaria; hipóteses testáveis.
3. Fundamentação	Normalização, stopwords, stemming, lematização, embeddings e relações linguísticas.
4. Materiais e métodos	Corpus, SPAmazon-QA, aliases, P0-P4, encoder, Top-10, regras de preservação.
5. Resultados	Hit@k, MRR, rankings, estratos e variações versus P0.
6. Análise de casos	Caso 11 + temporalidade, negação, quantidade e comparação.
7. Discussão	Ganhos, degradações, causas linguísticas e implicações para RAG.
8. Limitações	Capítulo como proxy, anotação qualitativa, um encoder/corpus, grupos desiguais.
9. Conclusão	Responder as duas perguntas e indicar continuidade no mestrado.

Decisões consolidadas nesta versão

- Mantido o estudo sem BM25 e sem geração por LLM.
- Mantida a baseline P0 e as variantes P1-P4.
- Adicionada pergunta secundaria sobre preservação de restrições linguísticas.
- Caso 11 passa a ser caso sentinela obrigatório.
- P2 usa stoplist congelada e auditada, com preservação de marcadores críticos definida antes dos resultados.
- Análise de contexto temporal/relacional complementa Hit@k e MRR, sem virar métrica automática sem anotação.
- cross_chapter_2 = cc2 = CC2 = Capítulo CC2 = Capítulo Cross Chapter 2.

Resumo operacional: mesmas 130 perguntas + mesmos chunks + mesmo encoder + cinco formas de preparar o texto; medir o ranking do capítulo correto e, nos casos críticos, verificar se a evidência recuperada respeita a relação linguística exigida pela pergunta.