

Impacto do pré-processamento linguístico na recuperação semântica de documentos científicos

Roteiro técnico e experimental atualizado - INF 791 / PLN

Ana Clara Guerra

Outubro de 2026

1. Visão geral, pergunta de pesquisa e escopo

Este trabalho investiga como operações clássicas de Processamento de Linguagem Natural (PLN) afetam a recuperação semântica no corpus científico utilizado pelo AmazoniaExpert.IA. O experimento principal permanece concentrado na etapa de recuperação: corpus, chunks, IDs, metadados, encoder, banco vetorial e conjunto de consultas são mantidos constantes, variando somente a preparação linguística do texto.

Pergunta de pesquisa principal:

Como diferentes estratégias de pré-processamento linguístico afetam a recuperação semântica de capítulos de origem de perguntas científicas sobre a Amazônia?

Análise secundária adicionada:

Quando o pré-processamento altera a recuperação em casos historicamente problemáticos, essa mudança também se traduz em melhora ou piora da resposta final gerada pelo RAG?

Objetivo geral

Avaliar, de forma controlada e reproduzível, o efeito de diferentes estratégias de pré-processamento sobre a recuperação densa de documentos científicos da Amazônia e, em um subconjunto crítico previamente definido, verificar se mudanças no retrieval se propagam para a qualidade da resposta final.

Objetivos específicos

- Reproduzir P0 como baseline do AmazoniaExpert.IA.
- Implementar P1-P4 e aplicar a mesma variante a corpus e consulta.
- Reconstruir cinco índices sob condições idênticas.
- Comparar Chapter Hit@1/@3/@5/@10, First Relevant Rank e MRR@10.
- Estratificar resultados por tipo de pergunta e dificuldade.
- Auditar casos com restrições linguísticas críticas: temporalidade, negação, quantidade e comparação.
- Selecionar antes de observar P1-P4 um subconjunto de casos históricos problemáticos e avaliar o efeito downstream na geração.
- Preservar toda a trilha de reprodutibilidade: hashes, ambientes, rankings, configurações, notas e justificativas.

Dentro e fora do escopo

Incluído: lowercase, stopwords controladas, lematização, stemming, embeddings densos, ChromaDB, ranking Top-10, métricas por capítulo, análise de casos críticos e geração secundária somente no subconjunto crítico.

Não incluído no experimento principal: BM25, recuperação híbrida, reranking, GraphRAG, novo chunking, nova extração de PDFs, expansão do corpus, fine-tuning do encoder ou do gerador.

A geração por LLM e o Juiz LLM deixam de estar totalmente fora do projeto: passam a integrar **somente uma análise secundária de causa-raiz**, sem substituir as métricas principais de retrieval.

2. Corpus e SPAmazon-QA

Corpus auditado

A baseline P0 foi exportada do ChromaDB preservado do TCC. A auditoria atual confirmou:

Item	Valor
Chunks	6.900
IDs de chunks únicos	6.900
Documentos canônicos	38
Capítulos regulares	34
Cross Chapters	2
Anexos	2
Dimensão do embedding	768

O texto armazenado para recuperação preserva a injeção de macrocontexto utilizada no TCC, com estrutura Chapter + Section + Content.

SPAmazon-QA

O arquivo SPAmazon-QA.json contém 130 objetos de avaliação.

Característica	Valor
Perguntas	130
IDs únicos	130
Direct	53
Indirect	77
Easy	7
Medium-Low	28
Medium-High	16
Hard	79

Campos usados no experimento principal:

- `id_questão`: chave da consulta.
- `conjunto_curado.pergunta`: consulta.
- `metadados_pergunta.capítulo_alvo`: rótulo operacional de origem.
- `metadados_pergunta.tipo`: estratificação Direct/Indirect.
- `metadados_pergunta.dificuldade`: estratificação por dificuldade.
- `metadados_pergunta.indice_subjetividade`: exploratório.

A `resposta_esperada` não participa da recuperação, mas será usada na análise secundária com Juiz LLM. As respostas e notas históricas permanecem como resultados anteriores e nunca são sobrescritas.

3. Canonicalização e auditoria de metadados

O SPAmazon-QA apresentou 39 grafias distintas de capítulo_alvo, reduzidas a 38 origens canônicas após normalização.

Equivalências confirmadas incluem:

Capítulo CC2 = Capítulo Cross Chapter 2 = cc2 = cross_chapter_2

Capítulo Cross Chapter 1 = cross_chapter_1

Capítulo 1 ... Capítulo 34 = chapter_01 ... chapter_34

Capítulo Annex 1 = annex_01

Capítulo Annex 2 = annex_02

Durante a auditoria do banco original foi detectada uma ambiguidade herdada do pipeline do TCC:

Chapter 1 -> chapter_number = 1

Cross Chapter 1 -> chapter_number = 1

Chapter 2 -> chapter_number = 2

Cross Chapter 2 -> chapter_number = 2

O campo source, entretanto, distingue corretamente os documentos. Assim, a avaliação atual deriva o ID canônico prioritariamente de source, preservando chapter_number original apenas para auditoria.

Contagens auditadas:

Documento	Chunks
Chapter 1	243
Cross Chapter 1	61
Chapter 2	229
Cross Chapter 2	18

Regra: se um valor não puder ser canônico de forma determinística, o pipeline deve interromper em vez de mapear silenciosamente para um valor genérico.

4. Variantes P0-P4 e regras congeladas

Variante	Transformação
P0	Texto original usado na recuperação, sem nova operação de PLN
P1	Lowercase somente
P2	P1 + remoção controlada de stopwords em inglês
P3	P1 + lematização em inglês
P4	P1 + Porter stemming

A mesma variante é aplicada ao texto dos chunks e a consulta. O rótulo de origem nunca é processado nem participa da busca.

Operadores semanticamente protegidos

A inspeção prévia mostrou que stopwords e transformações morfológicas podem apagar relações importantes. Foi congelada antes dos resultados uma lista de operadores protegidos, incluindo termos de:

- temporalidade: before, after, since, until, during, between, from, to, earlier, later, prior, following;
- negação: no, not, nor, never, without;
- lógica: and, or, but, if, whether;
- quantificação: all, any, each, every, only, same;
- comparação/direção: more, less, most, least, than, above, below, under, over, greater, lower, higher.

A lista não será alterada após a observação dos rankings P0-P4.

Validação prévia

Foram testados manualmente exemplos de temporalidade, negação, comparação, quantidade e siglas. Também foram executados 10 testes automatizados com pytest, todos aprovados.

Hash SHA-256 congelado de `src/preprocess.py`:

050AEC627D8DA62FAC2F0B8E364FDC9D3102368F1464B17240187E964ACA6610

5. Corpora derivados e reprodutibilidade

Os corpora P1-P4 foram gerados a partir exatamente dos mesmos 6.900 registros de P0.

Todos preservaram:

- 6.900 chunks;
- 6.900 IDs únicos;
- 38 documentos canônicos;
- zero textos vazios;
- zero alterações de metadados.

Variante	Reducao de caracteres	SHA-256
P0	-	1fce41571ca46ccca48c9aaf2fc07013a
P1	0,00%	0e1efcd0f921f08956529d89eb0ff267d
P2	11,28%	48dc79cf004d56c5f25905532564fc8a0
P3	2,98%	ae8b5ad596327372a3b5b6cf8e92a422d
P4	11,06%	70fd5435015ba57aea468b8148190c1cc

P1 altera a caixa, mas não o comprimento dos textos.

6. Experimento principal de recuperação

Fluxo controlado:

mesmos 6.900 chunks

|

v

P0 / P1 / P2 / P3 / P4

|

v

all-mpnet-base-v2 (768 dimensões)

|

v

5 índices ChromaDB / HNSW reconstruídos

|

v

130 consultas por variante

|

v

Top-10

|

v

Chapter Hit@k + First Relevant Rank + MRR@10

Para evitar que a baseline histórica use um HNSW construído em condições diferentes dos novos índices, o experimento principal reconstrui também um P0_CONTROLLED. P0-P4 são indexados pelo mesmo script, com a mesma ordem de insercao, mesmo batch size, mesmas versões de software e mesmo encoder.

O banco original do TCC permanece preservado apenas como referência histórica.

Etapas operacionais

1. Congelar fontes e hashes.
2. Validar 130 perguntas, 38 origens e 6.900 chunks.
3. Reproduzir a baseline histórica.
4. Congelar P0-P4 e executar testes.
5. Gerar corpora derivados.
6. Reconstruir P0-P4 sob condições controladas.
7. Aplicar Pk a cada consulta e recuperar Top-10.
8. Persistir rankings completos.
9. Calcular métricas por pergunta e agregadas.
10. Comparar Pk contra P0_CONTROLLED.
11. Estratificar por tipo e dificuldade.
12. Auditar casos linguisticamente críticos.
13. Executar a análise secundária downstream nos casos pre-selecionados.

7. Métricas e interpretação

Metрика	Definição
Chapter Hit@1/@3/@5/@10	1 se pelo menos um chunk do documento-alvo aparece ate k; 0 caso contrario
First Relevant Rank MRR@10	primeira posição de um chunk do documento-alvo média de 1/rank do primeiro acerto ate a posição 10; zero em ausência
Delta vs P0	diferença pareada por pergunta entre Pk e P0_CONTROLLED

O rótulo de origem funciona como **proxy operacional de realocização da fonte**, não como julgamento completo de relevância. Um chunk de outro capítulo pode conter evidência cientificamente valida.

Sem rótulos de relevância por chunk, Precision@k e nDCG não serão métricas principais.

Análises planejadas:

- global;
- Direct vs Indirect;
- Easy / Medium-Low / Medium-High / Hard;
- ganhos e perdas por pergunta;
- casos de temporalidade, negação, quantidade e comparação;
- Caso 11 como sentinela temporal.

8. Baseline histórica reproduzida

A reprodução atual do banco P0 preservado produziu:

Metrica	Resultado
Hit@1	103/130 = 79,23%
Hit@3	117/130 = 90,00%
Hit@5	121/130 = 93,08%
Hit@10	124/130 = 95,38%
MRR@10	0,8507

O TCC histórico registrou 118 sucessos e 12 falhas no equivalente operacional de Recall@5 (90,8%). A reprodução atual concordou em 127/130 consultas (97,69%). As tres divergências ocorreram exclusivamente nos IDs 96, 97 e 98, todos do Annex II, que passaram a ser recuperados na primeira posição na base atualmente preservada.

Não ha evidência suficiente para atribuir uma causa unica a essa diferença histórica. Ela será mantida como divergencia de reprodução documentada.

Caso 11 - sentinela temporal

A pergunta exige atividades que se expandiram **since the 1970s**, enquanto P0 recuperou predominantemente o Chapter 11, cujo título delimita o período **to the 1970s**. O alvo Chapter 17 não apareceu no Top-10.

Esse caso será acompanhado nas cinco variantes e também na análise secundária de geração.

9. Nova análise secundária: efeito downstream nos casos críticos

Esta etapa foi adicionada para responder a uma pergunta complementar: uma mudança de ranking é útil apenas se o contexto recuperado também melhorar a resposta final?

Seleção pré-registrada do subconjunto

A seleção é feita **antes de observar os resultados P1-P4**, evitando cherry-picking.

Regra de inclusão:

nota histórica do AmazoniaExpert.IA ≤ 3

OU

capítulo_recuperado histórico == False

Contagens no SPAmazon-QA:

- 23 casos com nota histórica 1, 2 ou 3;
- 12 casos históricos com falha de recuperação;
- 3 casos pertencem aos dois grupos (IDs 11, 102 e 124);
- **32 casos críticos únicos.**

Distribuição das 23 notas baixas:

- nota 1: 1 caso;
- nota 2: 4 casos;
- nota 3: 18 casos.


IDs do subconjunto crítico:

9, 11, 15, 27, 34, 35, 36, 53, 58, 59, 63, 65, 67, 72, 77, 83,
90, 96, 97, 98, 99, 100, 102, 104, 105, 106, 110, 116, 117, 124, 125, 126

10. Pipeline downstream: isolar retrieval de geração

O pré-processamento não deve deformar diretamente o contexto entregue ao gerador. Portanto, a recuperação usa Pk, mas a geração recebe **o texto original P0 dos mesmos chunk IDs recuperados**.

Fluxo por pergunta e variante:



Essa escolha impede que stemming, lematização ou remoção de stopwords prejudiquem a **redação do contexto** entregue ao LLM. Assim, a variável de interesse continua sendo a seleção do contexto pelo recuperador.

Por que Top-5 na geração?

O experimento principal salva Top-10 para métricas de retrieval. Na geração downstream será usado Top-5, porque a arquitetura original do AmazoniaExpert.IA foi configurada com cinco chunks, preservando comparabilidade com o TCC.

Configuração do ClimateChat a reproduzir

- modelo local: ClimateChat em formato GGUF;
- temperature = 0.1;
- top_p = 0.9;
- repeat_penalty = 1.15;
- max_tokens = 2048;
- n_ctx = 8192;
- mesmo prompt final do AmazoniaExpert.IA, com restrição para responder a partir do contexto recuperado.

Caso o código executável final do TCC difira do texto documentado, a configuração efetivamente utilizada deverá ser registrada antes da nova rodada.

11. Juiz LLM e controle de comparabilidade temporal

O Juiz LLM será mantido o mais próximo possível do protocolo do TCC:

- modelo: llama-3.3-70b-versatile via Groq;
- temperature = 0.0;
- persona: Professor Doutor especialista na Amazônia;
- entrada: pergunta + gabarito + resposta do sistema;
- saída JSON: nota 1-5 + justificativa técnica.

Escala:

Nota	Interpretação
1	Incorreta / irrelevante
2	Insuficiente, com erros graves ou omissões centrais
3	Parcial, correta em parte mas incompleta ou superficial
4	Boa, majoritariamente correta com falhas mínimas
5	Excelente, completa e cientificamente aderente

Reavaliação das respostas históricas

Mesmo com temperature=0.0, uma API externa pode mudar de infraestrutura, checkpoint ou comportamento ao longo do tempo. Para reduzir esse problema, o desenho terá dois registros distintos:

1. **nota histórica do TCC** - preservada apenas como referência;
2. **nota atual** - obtida na mesma rodada do juiz para todas as respostas comparadas.

Para os 32 casos críticos, serão submetidos ao juiz atual:

- 32 respostas históricas do AmazoniaExpert.IA, reavaliadas;
- 32 respostas P0_CONTROLLED;
- 32 respostas P1;
- 32 respostas P2;
- 32 respostas P3;
- 32 respostas P4.

Total planejado: **192 avaliações atuais do Juiz LLM**.

Se o modelo de juiz originalmente utilizado não estiver mais disponível, qualquer substituição deverá ser explicitamente registrada e as notas novas não deverão ser tratadas como diretamente equivalentes às históricas.

12. Análise dos 32 casos críticos

Para cada caso, a tabela final deve reunir:

- ID da pergunta;
- pergunta e gabarito;
- documento-alvo;
- nota histórica do TCC;
- booleano histórico de recuperação;
- rank do primeiro documento correto em P0-P4;
- capítulos presentes no Top-5 de cada variante;
- resposta histórica;
- resposta P0_CONTROLLED;
- respostas P1-P4;
- nota atual e justificativa do juiz para cada resposta.

Comparacoes principais:

$\Delta Judge(P1) = NotaAtual(P1) - NotaAtual(P0_CONTROLLED)$
 $\Delta Judge(P2) = NotaAtual(P2) - NotaAtual(P0_CONTROLLED)$
 $\Delta Judge(P3) = NotaAtual(P3) - NotaAtual(P0_CONTROLLED)$
 $\Delta Judge(P4) = NotaAtual(P4) - NotaAtual(P0_CONTROLLED)$

Relatar, para cada variante:

- número de casos que melhoraram;
- número de empates;
- número de casos que pioraram;
- média e mediana das notas;
- transições de nota (por exemplo, 3 -> 4);
- casos em que o retrieval melhorou mas a resposta não;
- casos em que o retrieval piorou e a resposta piorou;
- casos em que a resposta mudou sem alteração relevante do rank.

Como o subconjunto foi selecionado justamente por desempenho histórico ruim/falha, essa etapa é **exploratória e de causa-raiz**, não uma estimativa não enviesada do desempenho global das 130 perguntas.

13. Dados derivados e arquivos de saída

Arquivos principais já existentes ou planejados:

```
data/reference/p0_chunks.jsonl
data/reference/spamazon_qa_questions.jsonl
data/processed/p1_chunks.jsonl
data/processed/p2_chunks.jsonl
data/processed/p3_chunks.jsonl
data/processed/p4_chunks.jsonl
```

```
results/raw/
results/metrics/
results/tables/
results/cases/
results/runs/
```

Para a nova etapa downstream, criar:

```
data/reference/downstream_critical_cases.jsonl
results/tables/downstream_critical_cases.csv
results/raw/downstream_retrieval_top5.csv
results/raw/downstream_generated_answers.csv
results/raw/downstream_judge_scores.csv
results/metrics/downstream_summary.csv
results/cases/downstream_case_reports/
```

O SPAmazon-QA.json original permanece somente leitura.

14. Stack e reprodutibilidade

Camada	Tecnologia
Linguagem	Python 3.13.3 no ambiente atual; ambiente original preservado para reprodução
Pre-processamento	re, NLTK, spaCy en_core_web_sm
Embeddings	sentence-transformers/all-mpnet-base-v2
Banco	ChromaDB / HNSW
Análise	pandas, numpy, matplotlib
Testes	pytest
Gerador downstream	ClimateChat GGUF via LlamaCpp
Juiz downstream	Groq / Llama-3.3-70B-Versatile, quando disponível
Versionamento	Git / GitHub + hashes SHA-256

Princípios:

- nenhum resultado manualmente corrigido sem registro;
- IDs imutáveis;
- metadados originais preservados;
- scripts determinísticas quando aplicável;
- versões de bibliotecas registradas;
- bancos Chroma experimentais fora do OneDrive;
- bancos vetoriais binários não precisam ser versionados no Git se forem reconstruíveis.

15. Cronograma revisado e status atual

Concluído

- auditoria do corpus P0;
- exportacao dos 6.900 chunks;
- separação correta dos 38 documentos canônicos;
- validação das 130 perguntas;
- reprodução da baseline histórica;
- definição e congelamento de P0-P4;
- validação manual do pré-processamento;
- 10 testes automatizados aprovados;
- geração dos corpora P1-P4;
- hashes e auditorias dos corpora;
- README e registro experimental iniciados.

Em execução

- construção controlada dos cinco índices P0-P4.

Próximas etapas

1. validar os cinco bancos controlados;
2. executar 130 x 5 consultas e salvar 6.500 posições Top-10;
3. calcular Hit@k e MRR@10;
4. comparar P1-P4 contra P0_CONTROLLED;
5. estratificar por tipo e dificuldade;
6. gerar subset fixo dos 32 casos críticos;
7. executar Top-5 e geração ClimateChat para esses casos;
8. submeter 192 respostas ao Juiz LLM atual;
9. analisar relacao retrieval -> geração;
10. produzir figuras, tabelas, discussão e conclusão.

16. Riscos e controles

Risco	Controle
Ambiguidade de Cross Chapters	canôncialização baseada em source
Diferença entre HNSW histórico e novos índices	reconstruir P0-P4 pelo mesmo script
Stopwords apagam relações	operadores protegidos congelados antes dos resultados
Stemming/lemas deformam contexto gerado	retrieval usa Pk, gerador recebe texto original P0 por chunk ID
Mudança do Juiz LLM ao longo do tempo	reavaliar respostas históricas na mesma rodada atual
Seleção oportunista de casos	regra dos 32 casos pré-definida antes de observar P1-P4
Acerto de origem != relevância absoluta	interpretar Chapter Hit como proxy operacional
Subconjunto crítico não representativo	tratar downstream como análise exploratória de causa-raiz
API indisponível/modelo alterado	registrar versao/substituição; não misturar notas sem ressalva

17. Estrutura final do relatório

1. **Introdução** - problema, AmazoniaExpert.IA, relevância de PLN e pergunta central.
2. **Fundamentação** - normalização, stopwords, stemming, lematização, embeddings, recuperação densa, RAG e avaliação por LLM.
3. **Materiais e métodos** - corpus, SPAmazon-QA, canônicização, P0-P4, índices controlados, métricas e subconjunto downstream.
4. **Resultados de retrieval** - Hit@k, MRR@10, ranks, comparações Pk x P0.
5. **Análises estratificadas** - Direct/Indirect, dificuldade e casos linguísticos.
6. **Análise downstream dos 32 casos** - mudanças de contexto, respostas ClimateChat, notas atuais do Juiz e causa-raiz.
7. **Discussão** - quando o pré-processamento ajuda, quando prejudica e por que ganho em retrieval pode não virar ganho de resposta.
8. **Limitações** - um encoder, corpus único, rótulo por capítulo, HNSW aproximado, subset crítico selecionado e variabilidade de serviços LLM externos.
9. **Conclusão** - resposta a pergunta principal e implicações para o AmazoniaExpert.IA e para o mestrado.

Conclusão metodológica esperada

O objetivo não é demonstrar que “mais pré-processamento é melhor”, mas identificar quais transformações alteram de forma útil ou prejudicial a recuperação semântica e, nos casos problemáticos, verificar se essas mudanças realmente se propagam para a resposta final do RAG.